

ML-analys för Avocado Toast Estates: Klassificering & Klustring

1 Mål & Valt spår

Beställaren, Avocado Toast Estates (ATE), vill dels ha en konkret modell som de kan använda som beslutstöd. Modellen ska snabbt kunna klassificera bostadsområden som "högprisområde" eller "ej högprisområde" och på så sätt hjälpa ATE att spara tid och pengar.

Avocado Toast Estates är också nyfikna på om det finns "naturliga grupper" i datan och är villiga att betala dyra konsultpengar för en kreativ undersökning med hjälp av PCA och KMeans.

Jag, en junior dataanalytiker med för mycket fritid, tackade ja till båda uppdragen. Inte bara på grund av konsultpengarna (...), men också för att alternativet var att förutsäga bostadsvärde för en annan kund och det lät inte lika roligt!


Avocado Toast Estate var mycket tydliga med att det var två olika uppdrag. Det första med ett konkret resultat: en användbar ML-modell. Det andra med mer fria tyglar, både i utförande och resultat. ATE vill därför få två olika notebooks.


2 Kort data-insikt (EDA)

- Datan saknade förhållandevis få värden:

	Saknade värden	Procent (%)
longitude	0	0.0
latitude	0	0.0
housing_median_age	0	0.0
total_rooms	0	0.0
total_bedrooms	207	1.0
population	0	0.0
households	0	0.0
median_income	0	0.0
median_house_value	0	0.0
ocean_proximity	0	0.0

- Två kolumner var "capped":





- Vilket kan ge problem för en framtida användning av modellen. Läs mer i [california-housing-analysis.ipynb](#).

3 Metod (ML-flöde)

- En av de första stegen är att dela upp datan i "Train" och "Test". Jag valde fördelningen 80/20 (80 % train, 20 % test).
- Testdatan "läggs åt sidan" och hålls långt borta från modellbyggandet innan det i slutet är dags att plocka fram den. Testdatan blir det slutliga provet för modellen: hur fungerar den på data den aldrig sett förut? Det blir en försmak på hur modellen kan tänkas fungera i produktion.
- Jag valde att testa 3 modeller (+ en dummy baseline): Logistic Regression, Decision Tree och Random Forest. Anledningen att jag valde dessa tre var för att få testa tre olika typer av algoritmer. En linjär och snabb (Logistic Regression) en icke-linjär (Decision Tree) och en ensemble-modell (Random Forest). Olika algoritmer gör olika bra ifrån sig på olika typer av data och utan en djupare EDA kändes det rimligt att testa lite av varje.
- De olika modellerna utvärderas med CrossValidation. Med CrossValidation ges möjligheten att i omgångar testa modellen på träningsdata som "leker" testdata. På så vis blir resultatet mer tillförlitligt.
- Jag valde F1-score för att utvärdera och rangordna de olika modellerna. F1-score ger balansen mellan Precision och Recall, vilket är en bra start när kunden önskar hjälp att prioritera mellan missa ett högprisområde (låg Recall), eller felaktigt flagga ett område (låg Precision).

4 Resultat

- Modellerna slog baseline klart och tydligt, visade liknande resultat, men där det ändå var en modell i topp:

Resultat av Cross-Validation:		
	model	mean_f1
1	RandomForest	0.715010
2	DecisionTree	0.670235
3	LogisticRegression	0.657440
4	Baseline	0.193707

- Efter optimering av Random Forest-modellen ökade F1-score med ytterligare 5,5 procentenheter. På träningsdata fick modellen ytterligare högre F1-score (0.837), vilket jag inte ansåg vara tillräckligt stor skillnad för att tyda på "overfitting".

5 Rekommendation

Jag rekommenderar Random Forest inställd med:

- `class_weight = "balanced_subsample"`
- `max_depth = 10`
- `min_samples_leaf = 5`
- `n_estimators = 200`

och att modellen implementeras med en threshold på 0.5.

Motivering:

- Högst F1-score, dvs bästa balansen mellan att hitta rätt områden och undvika felaktiga flaggninar.
- Hög Recall. Modellen fångar 86 % av alla faktiska högrisområden.
- Får Avocado Toast Estates 100 områden i knät behöver teamet endast granska 24 områden för att hitta 18 av 20 högrisområden. Detta innebär en effektivisering av arbetsprocessen med ca 76 % jämfört med att granska alla områden manuellt.

6 Risker & Begränsningar

- Modellen är tränad på historisk data. Allt eftersom verkligheten förändras kommer modellen prestera sämre
- Modellen vet inte skillnaden på ett 52 år gammalt hus och ett 90 år gammalt hus, vilket kan ha stor betydelse för husets värdering
- Fastighetsvärde påverkas stort av variabler som inte finns med i datan, så som tillgång till kollektivtrafik eller annan service, framtida stadsplanering eller brottslighet. Det som modellen säger är ett troligt högrisområde kan därför vara helt felaktigt.
- Datasetet är specifikt för Kalifornien och begränsar användningen till just detta geografiska område

7 Öövervakad inlärning

Oövervakad inlärning innebär att modellen tränas på data som inte har några "etiketter". Modellen hittar därför inga svar som "ja, det är ett högrisområde" eller "bostadsvärdet för en sån här bostad är 500 000 \$", utan resultatet blir istället mönster, strukturer och grupperingar i datan.

Avocado Toast Estates nytta av oövervakad inlärning är därför inte "här har ni en topplista med hus som kommer sälja dyrt" utan ett komplement till deras branschkunskap: "det här området liknar platser där bostäderna går för många money, men har det senaste inte sålt så bra. Investeringsmöjlighet, kanske?"

PCA (Principal Component Analysis) används för att reducera antalet dimensioner. Med PCA kan man koka ihop 20 variabler till 4 komponenter som fortfarande förklarar en stor del av datan. Klustering däremot används för att gruppera datan i k antal kluster, baserat på liknande egenskaper.

Risker/fallgropar:


- Både PCA och KMeans bygger på avstånd. Det är därför mycket viktigt att komma ihåg att *skala* datan innan.
- KMeans är känslig för outlier, vilket går att se bevis på i mina cluster-analysis-notebooks. 5 extrema värden "stal" ett helt kluster!

Min strategi var att först göra PCA för att korta ner antalet variabler och sammanfatta datan. Med en scree plot och kumulativ explained variance kom jag fram till att 4 komponenter behövs för att förklara 80 % av datan.

Dessa 4 komponenter blir som 4 skalor: lyx vs enklare bostadsområden, idyll vs nybyggnadsområde för barnfamiljer, traditionell stadskärna vs massproducerat studentområde, landet vs modernt vid havet.

Jag använde sedan PCA-komponenterna i min KMeans. För att välja antalet kluster kollade jag på "Elbow" och silhouette score. 5 kluster såg enligt "Elbow" och silhouette score mest lämpligt ut och gav följande segment: Hollywood-vibe, Old Money, Vischan, Hyreslägenheter med bra läge och Förorten.

De features som ser ut att påverka mest är bedrooms_per_room, rooms_per_household och median_income. Dessa 3 variabler styr det nya PC1 indexet och förklarar 40 % av datan.



Detta går att utläsa i heatmap:en över PCA Loadings.

Begränsningar och nästa steg:

- KMeans förutsätter att kluster är cirkulära/sfäriska, och så behöver ju inte verkligheten se ut. Detta innebär att KMeans kan tvinga in datapunkter i "fel" cirkel bara för att de ligger närmast medelpunkten rent matematiskt.
- Därför rekommenderar jag att nästa steg är att förbättra analysen med hjälp av DBSCAN eller Hierarkisk klustring. Dessa algoritmer är bättre på att hantera kluster med oregelbundna former och kräver dessutom inte att man anger antalet kluster på förhand.

8 Självreflektion

- Ett urval av det jag gjorde bra:
 - En sanity check för Preprocessing-pipelinan. Den kändes som en "svart låda" därför var det skönt att med hjälp av "dummy-data" kontrollera att koden gjorde det jag ville
 - Räkneexempel på vad som händer om beställaren använder modellen på 100 områden. Jag ville ha något mer realistiskt att utgå ifrån, för hur ofta är det 2400 nya områden som ett fastighetsbolag ska kolla på?
 - Jag hittade 5 extrema outliers som förstörde hela min KMeans, och istället för att rycka på axlarna och gå vidare, ville jag envetet se hur det blir om man tog bort dem. Så jag gjorde det enkelt för mig och kopierade hela notebook:en. Hanterade outliers på ett strängare sätt och utvärderade det resultatet istället.
 - Genomgående snygg, enhetlig och strukturerad kod.
- Det som var allra svårast var att förstå hur PCA och KMeans kan användas av beställaren. Jag hade en röst i bakhuvudet som hela tiden sa "men med domänkunskap och erfarenhet så vet man det här ändå?? Man har ju koll på området man verkar i." Men KMeans verkar ju riktigt bra på att hitta allt konstigt i datan så man kan sortera ut det innan man börjar modellera.
- Jag tycker min inlämning motsvarar betyg VG.
Motivering:
 - I kursplanen står det att den studerande ska "redogöra för och kritiskt diskutera modellval, modellanpassning och modellutvärdering". Detta gör jag i den här rapporten (främst under punkt 5 Rekommendation, 6 Risker & Begränsningar, och Begränsningar och nästa steg under 7 Ööversvakad inläring), men också löpande i notebook:en. Vilket är anledningen till varför den här rapporten är 5 sidor istället för 1-2 och varför det blev 3 notebooks istället för 1.
 - Det står också "i en skriftlig rapport lösa ett problem genom att implementera metoder och modeller från maskininläring på ett fördjupat sätt med hög säkerhet". Jag har i `california-housing-analysis.ipynb` och `cluster-analysis-2.ipynb` implementerat metoder och modeller från maskininläring (Random Forest, PCA och KMeans) på, vad jag tycker, ett fördjupat sätt med hög säkerhet. Jag undviker "dataläckage" genom att följa ML-flödet och använder funktioner och verktyg såsom Pipeline, SimpleImputer och StandardScaling. Jag förklarar mina resonemang skriftligt i den här rapporten samt i notebook:en.